

Avaliação Experimental do CEGIS com Prompt Anti-Trapaga na Resolução do ARC-AGI-1

Izadora Candotti de Oliveira¹

¹Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)

Abstract

Este trabalho investiga a síntese de programas por meio da abordagem CEGIS (*Counterexample-Guided Inductive Synthesis*) guiada por Modelos de Linguagem de Larga Escala (LLMs) para a resolução de tarefas do benchmark ARC-AGI-1. Identificou-se que o método CEGIS tradicional sofre com dois gargalos severos: a **Falsa Convergência (FC)** — quando o código satisfaz os exemplos de treino por memorização superficial (*hardcoding*), mas falha no teste oculto — e a **Não-Convergência no Treino**, causada por um ciclo de correções locais conflitantes. Para mitigar essas falhas de forma computacionalmente barata, propõe-se uma intervenção de custo zero: a injeção de regras Anti-Trapaga (*Anti-Cheat*) no feedback semântico dos contraexemplos, proibindo expressamente a fixação de coordenadas e condicionais por índice. O método foi avaliado em 100 tarefas utilizando os modelos Gemini 3.1 Flash-Lite e Gemma 4 26B sob execução estrita em *sandbox* Python. Os resultados demonstraram saltos de acurácia no teste oculto de +8,0% no Gemini (47,0% para 55,0%) e +9,0% no Gemma (31,0% para 40,0%). Conclui-se que o ganho primário provém da atuação do prompt como um regularizador indutivo dupla-face, que poda hipóteses degeneradas durante o treino e força o modelo a sintetizar transformações geométricas universais.

1 Introdução

O *Abstraction and Reasoning Corpus* (ARC-AGI) estabeleceu-se como um dos principais benchmarks para testar o raciocínio abstrato em sistemas de Inteligência Artificial (Chollet 2019; Projeto ARC-CEGIS 2026j). Na abordagem de Síntese por Exemplos (*Programming-by-Example* – PBE), a tarefa consiste em induzir uma função determinística em Python que transforme matrizes 2D de entrada nas saídas correspondentes com base em um pequeno conjunto de demonstrações de treino (Projeto ARC-CEGIS 2026j).

Para aumentar a taxa de acerto de LLMs nesse domínio, emprega-se o laço de refinamento CEGIS (*Counterexample-Guided Inductive Synthesis*), onde o modelo recebe feedback semântico a cada código incorreto gerado (Abate et al. 2018; Projeto ARC-CEGIS 2026i). Contudo, foram identificadas no CEGIS Padrão duas limitações críticas:

1. **Falsa Convergência (FC):** O modelo cria atalhos trapaceiros (como rotinas baseadas em condicionais literais

para os índices de treino), fazendo o verificador de treino aprovar um algoritmo incapaz de generalizar para o teste oculto (Projeto ARC-CEGIS 2026h,j).

2. **Não-Convergência por Oscilação Local Conflitante:** Ao tentar corrigir uma falha no Exemplo 0, o modelo insere um remendo local que desconfigura o Exemplo 1. Na iteração seguinte, ajusta o Exemplo 1 e desfaz a correção do Exemplo 0, esgotando o limite de iterações sem jamais convergir no treino (Projeto ARC-CEGIS 2026h,f).

Este trabalho propõe e avalia a estratégia **CEGIS + Anti-Trapaga**. A hipótese central é que proibir a memorização rasa no feedback semântico atuará como uma restrição indutiva que guiará o LLM em direção a invariantes geométricas universais, reduzindo a Falsa Convergência e aumentando a taxa de sucesso no teste oculto (Projeto ARC-CEGIS 2026h,e).

As principais contribuições deste artigo são: (1) a caracterização empírica de dois modos de falha recorrentes do CEGIS neural no ARC-AGI (a Falsa Convergência e a Oscilação por Ajustes Locais Conflitantes); (2) a demonstração de um aumento de acurácia de +8,0% e +9,0% sem custos adicionais de treinamento ou inferência; (3) a evidência empírica de que a restrição atua primordialmente destravando a convergência no treino; e (4) a identificação das limitações sistemáticas da auditoria automatizada de código baseada em modelos de linguagem (Projeto ARC-CEGIS 2026l,b).

2 Trabalhos Relacionados

A aplicação do CEGIS acoplado a modelos de linguagem une a verificação formal determinística, executada em ambientes isolados (*sandbox*), à capacidade generativa dos LLMs (Solar-Lezama 2008; Abate et al. 2018). Embora pesquisas recentes busquem aumentar o desempenho dos modelos expandindo o número de amostras ou aplicando algoritmos de busca em árvore, pouca atenção é dada a como o refinamento iterativo sem restrições pode prejudicar a busca por soluções. Quando as mensagens de feedback não impõem limites claros, o modelo tende a degradar a qualidade de suas hipóteses, recorrendo a atalhos superficiais de memorização ou a correções locais que impedem a generalização do algoritmo.

Paralelamente, a auditoria das funções geradas automatizada por modelos de linguagem tornou-se uma prática comum para avaliação qualitativa (Zheng et al. 2023). Neste

estudo, demonstra-se que, embora a inspeção por LLMs identifique facilmente padrões sintáticos óbvios (*hardcoding* direto), ela não é capaz de prever de forma confiável se a função matemática proposta é generalizável para os testes ocultos.

3 Abordagem Proposta

A intervenção proposta, denominada **CEGIS + Anti-Trapaça**, modifica o laço de síntese iterativa inserindo restrições comportamentais no feedback do verificador (Projeto ARC-CEGIS 2026j,e).

3.1 Isolamento Estrito de Variáveis

Para garantir que a única diferença entre as abordagens seja o conteúdo do *feedback*, o *prompt* inicial é rigorosamente idêntico em ambas as estratégias (Padrão e Anti-Trapaça). Como na primeira iteração o modelo ainda não teve acesso às saídas esperadas, qualquer tentativa de memorização de resultados é logicamente impossível nesse estágio. (Projeto ARC-CEGIS 2026h,i). Dessa forma, isola-se o impacto da intervenção no laço de refinamento semântico.

3.2 Injeção de Regras Anti-Trapaça no Feedback

A divergência ocorre exclusivamente a partir do primeiro contraexemplo. Enquanto o CEGIS Padrão envia apenas a entrada, a resposta esperada e o erro retornado, a variante Anti-Trapaça anexa as seguintes diretrizes explícitas (Projeto ARC-CEGIS 2026e):

- Do NOT `hardcode` coordinates or branch on specific example indices; provide a single uniform geometric/mathematical transformation.
- Do NOT memorize or replicate specific output grids from the examples; the function must generalize.

3.3 Gestão de Contexto e Proteção de Tokens

A fim de evitar que o tamanho do prompt cresça linearmente a cada iteração, aplica-se a poda de contexto (*Context Pruning*). Em vez de acumular o histórico completo de tentativas, cada requisição é reconstruída contendo estritamente quatro elementos essenciais: (1) O prompt inicial global; (2) A especificação original da tarefa com os exemplos de treino; (3) O código gerado como resposta no turno anterior; e (4) O contraexemplo gerado. Essa abordagem mantém o consumo de *tokens* constante ($O(1)$) ao longo do refinamento (Projeto ARC-CEGIS 2026k).

4 Metodologia Experimental

4.1 Dataset e Modelos Avaliados

Foram utilizadas 100 tarefas do conjunto de treinamento do benchmark ARC-AGI-1 (Projeto ARC-CEGIS 2026g,d). A avaliação foi conduzida em duas rodadas paralelas sobre dois modelos representativos: **Gemini 3.1 Flash-Lite** e **Gemma 4 26B A4B-IT**: (Projeto ARC-CEGIS 2026c). Ambos os modelos operaram em temperatura estritamente nula ($T = 0,0$) para assegurar a reprodutibilidade determinística das inferências (Projeto ARC-CEGIS 2026k,b).

4.2 Ambiente de Execução em Sandbox

O código Python gerado pela LLM é executado em um ambiente isolado (`sandbox.py`) com as seguintes garantias (Projeto ARC-CEGIS 2026a):

- **Isolamento de Processo e Limite de Tempo:** Cada código candidato é executado em um subprocesso efêmero isolado, controlado por um limite rígido de tempo (`timeout = 2.0s`), restrição que garante a interrupção de laços infinitos. Os algoritmos corretos executam em poucos milissegundos, portanto, qualquer execução que exceda esse limiar é tratada como falha por divergência. (Projeto ARC-CEGIS 2026a).
- **Proibição de Importações e Restrição do Escopo:** O ambiente bloqueia o carregamento de bibliotecas externas, restringindo o interpretador às primitivas nativas do Python. Essa restrição cumpre um duplo propósito: garante a segurança do sandbox contra execuções maliciosas e força o modelo a construir a lógica matemática do zero, impossibilitando que a solução seja terceirizada para abstrações de alto nível. (Projeto ARC-CEGIS 2026e,a).
- **Validação Exata:** Uma função só é considerada correta para uma matriz se satisfizer as dimensões exatas e a igualdade de valores célula a célula (Projeto ARC-CEGIS 2026a).

4.3 Auditoria por Modelo de Linguagem

Para além da verificação quantitativa por execução determinística, implementou-se uma camada de auditoria qualitativa automatizada no módulo `analysis/analyze_false_convergence.py`. Essa infraestrutura emprega um modelo de linguagem independente como juiz (*Gemini Flash*, $T = 0,0$) para inspecionar e classificar o código-fonte Python final produzido em cada tarefa (Projeto ARC-CEGIS 2026m).

O protocolo de auditoria foi estruturado para receber o código gerado e retornar uma resposta em formato JSON contendo: (1) um sinalizador binário de memorização (*hardcoded*); (2) o nível de confiança do diagnóstico (*high*, *medium* ou *low*); (3) uma justificativa em texto livre (*evidence*); e (4) uma taxonomia de padrões identificados, abrangendo categorias como ramificação por exemplo (`EXAMPLE_INDEXING`), fixação de coordenadas (`COORDINATE_HARDCODING`) e replicação literal de matrizes (`OUTPUT_REPLICATION`) (Projeto ARC-CEGIS 2026m).

4.4 Métricas de Avaliação

Formularam-se as seguintes métricas formais:

- **Acurácia de Teste:** Proporção de tarefas que obtiveram 100% de acerto nos pares de teste ocultos (Projeto ARC-CEGIS 2026l).
- **Convergência de Treino:** Percentual de tarefas em que o código passou em 100% dos exemplos de treino no limite de $T_{\max} = 5$ iterações (Projeto ARC-CEGIS 2026i).

- **Falsa Convergência (FC):** Tarefas em que o código convergiu no treino, mas errou o teste oculto:

$$FC = (\text{converged_train} = \text{True}) \wedge (\text{success_test} = \text{False}) \quad (1)$$

5 Resultados Experimentais

A Tabela 1 apresenta a consolidação dos resultados obtidos nas 100 tarefas avaliadas (Projeto ARC-CEGIS 2026l).

5.1 Mecanismo de Falha: Oscilação por Ajustes Locais Conflitantes

No paradigma CEGIS Padrão, a interação iterativa com o verificador frequentemente induz o modelo a uma dinâmica que denominaremos "**Oscilação por Ajustes Locais Conflitantes**". Ao receber o diagnóstico de erro sobre uma demonstração de treino específica, o LLM tende a aplicar uma correção superficial restrita àquele caso (inserindo condicionais por índice de exemplo ou checagens de coordenadas fixas). Embora essa alteração pontual satisfaça o corrente caso de exemplo falho, ela frequentemente invalida casos tratados e validados anteriormente. No turno seguinte, ao tentar corrigir a nova falha reportada, o modelo desfaz a lógica superficial adicionada anteriormente, entrando em um ciclo de ajustes divergentes que consome todo o orçamento de iterações sem alcançar a convergência no conjunto de treino (Projeto ARC-CEGIS 2026f,m).

Durante a análise dos experimentos realizados, descobriu-se que, embora esse não fosse seu propósito original, a introdução das restrições Anti-Trapaça atua também como um **regularizador indutivo** que elimina essa vulnerabilidade. Ao proibir expressamente o uso de ramificações por índice e coordenadas fixas, a regra poda as hipóteses degeneradas da árvore de busca. O modelo é forçado a abandonar a tentativa de remendos locais e a buscar uma transformação geométrica ou matemática global e invariante, capaz de satisfazer todas as demonstrações simultaneamente (Projeto ARC-CEGIS 2026f).

5.2 Análise do Gemini 3.1 Flash-Lite

No modelo Gemini 3.1 Flash-Lite, a estratégia Anti-Trapaça elevou a acurácia no teste de 47,0% (47/100) para 55,0% (55/100), representando um salto líquido de +8,0% em relação ao Padrão. O impacto mais notável da intervenção incidu sobre as ocorrências de Falsa Convergência, que despencaram de 6 casos absolutos no Padrão para apenas 2 no Anti-Trapaça (uma redução de 66,7%) (Projeto ARC-CEGIS 2026l). Sob a perspectiva proporcional das tarefas que obtiveram sucesso no treino, a taxa de respostas enganosas caiu de 11,54% (6/52) para 3,57% (2/56), sinalizando maior confiabilidade nos algoritmos aprovados nos casos de exemplo. (Projeto ARC-CEGIS 2026l,f).

A análise do histórico de execução das 6 tarefas que sofreram Falsa Convergência na abordagem Padrão revelou três comportamentos qualitativos (Projeto ARC-CEGIS 2026f,m):

1. **Conversão Direta em Acerto Generalizável (2 tarefas):** Nas tarefas 1f85a75f e 321b1fc6, a regra Anti-Trapaça bloqueou o atalho trapaceiro gerado pelo Padrão

e guiou o modelo à síntese da transformação geométrica válida (Projeto ARC-CEGIS 2026f).

2. **Prevenção de Falsos-Positivos no Treino (2 tarefas):** Nas tarefas 017c7c7b e 27a28665, o Padrão aceitou códigos com remendos locais na iteração 4 (Projeto ARC-CEGIS 2026f). A variante Anti-Trapaça rejeitou essas hipóteses; contudo, o modelo esgotou o limite de iterações sem conseguir sintetizar a transformação generalizável correta (Projeto ARC-CEGIS 2026f).
3. **Ambiguidade Inerente da Tarefa (2 tarefas):** Nas tarefas 05269061 e 11852cab, o tamanho reduzido do conjunto de demonstração de treino admitia mais de uma regra logicamente consistente, fazendo com que ambas as abordagens formulassem hipóteses válidas no treino que divergiram da intenção do teste oculto. Consequentemente, a intervenção Anti-Trapaça não foi capaz de prevenir esses dois casos, uma vez que o erro não advém de atalhos no código. (Projeto ARC-CEGIS 2026f).

Na matriz de desfechos cruzados 2×2 (44 acertos mútuos e 42 falhas mútuas), a abordagem Anti-Trapaça conquistou 11 vitórias exclusivas contra apenas 3 do Padrão (Projeto ARC-CEGIS 2026m). A investigação da origem dessas 11 vitórias revelou que além de sanar Falsas Convergências (responsáveis por 2 vitórias), a estratégia superou o problema da Não-Convergência no treino em 9 tarefas por meio da eliminação da Oscilação por Ajustes Locais Conflitantes. (Projeto ARC-CEGIS 2026f).

5.3 Análise do Gemma 4 26B

No modelo Gemma 4 26B, o ganho de acurácia foi ainda maior, subindo de 31,0% para 40,0% (+9,0%) (Projeto ARC-CEGIS 2026l). Observou-se 10 vitórias exclusivas do Anti-Trapaça contra apenas 1 do Padrão (Projeto ARC-CEGIS 2026m).

Diferentemente do observado no Gemini, a contagem absoluta de Falsa Convergência no Gemma manteve-se baixa e constante com 2 ocorrências em ambos os modos (Projeto ARC-CEGIS 2026l). Por outro lado, a taxa de convergência no conjunto de treino registrou um salto significativo, subindo de 32,0% (32/100) no Padrão para 41,0% (41/100) no Anti-Trapaça (Projeto ARC-CEGIS 2026l,f). Isso evidencia que o gargalo dominante na síntese com este modelo não era a aprovação de códigos fraudulentos, mas a Oscilação por Ajustes Locais Conflitantes (Projeto ARC-CEGIS 2026f). Das 41 tarefas que atingiram convergência de treino sob a regra Anti-Trapaça, 40 passaram perfeitamente no teste oculto (97,56% de eficiência de generalização) (Projeto ARC-CEGIS 2026f).

Um caso bastante ilustrativo do que ocorreu nesse experimento é a tarefa 3aa6fb7a: no Padrão, o modelo tentou corrigir o Exemplo 0 inserindo condicionais locais que quebravam o Exemplo 1, oscilando até a iteração 5 sem convergir; com o Anti-Trapaça, o modelo identificou o operador geométrico invariante (identificação de componentes conexos) e convergiu com sucesso na iteração 2 (Projeto ARC-CEGIS 2026f).

Métrica	Gemini (Padrao)	Gemini (Anti)	Δ Gem.	Gemma (Padrao)	Gemma (Anti)	Δ Gemm.
Acurácia (Teste Oculto)	47,0%	55,0%	+8,0%	31,0%	40,0%	+9,0%
Convergência (Treino)	52,0%	56,0%	+4,0%	32,0%	41,0%	+9,0%
Ocorrências Absolutas de FC	6	2	-66,7%	2	2	0,0%
Taxa de FC (sobre Treino Convergido)	11,54%	3,57%	-7,97 p.p.	6,25%	4,88%	-1,37 p.p.
Média de Iterações / Tarefa	3.18	3.03	-0.15	3.81	3.61	-0.20
Total de Requisições LLM	318	303	-4,7%	381	361	-5,2%

Table 1: Comparativo global de desempenho entre CEGIS Padrão e CEGIS Anti-Trapça ($N = 100$ tarefas) (Projeto ARC-CEGIS 2026l).

6 Discussão

6.1 Redução de Custos e Eficiência Computacional

Ao eliminar ciclos infrutíferos de remendos locais, o CEGIS Anti-Trapça convergiu em menos turnos (Projeto ARC-CEGIS 2026f). Houve uma redução no consumo total de requisições à API de -4,7% no Gemini (303 chamadas contra 318) e de -5,2% no Gemma (361 chamadas contra 381), tornando o sistema simultaneamente mais acurado e mais barato (Projeto ARC-CEGIS 2026l,m).

6.2 Limitações da Auditoria Neural

A abordagem da auditoria automatizada por uma LLM foi útil ao trabalho, pois permitiu comprovar que a intervenção eliminou com sucesso os padrões de trapça sintática direta (ex.: `if example_idx == 0` ou condicionais de coordenadas literais), demonstrando a alteração comportamental do modelo no nível do código.

É relevante mencionar que, embora o juiz neural identifique violações sintáticas explícitas com alta confiança, ele apresenta baixa confiança ou falha ao diagnosticar códigos visualmente limpos que atingem Falsa Convergência devido a ambiguidade inerente da tarefa (subespecificação dos exemplos). Essa limitação reforça que a auditoria automatizada por LLMs não substitui a verificação determinística e exata em *sandbox*.

7 Conclusão

Este estudo demonstrou que a injeção de restrições Anti-Trapça no feedback semântico do CEGIS constitui uma intervenção eficiente, reproduzível e de custo nulo para a síntese de programas mediada por LLMs (Projeto ARC-CEGIS 2026j,m). A aplicação da regra elevou a acurácia de generalização no par de teste oculto em +8,0% no Gemini 3.1 Flash-Lite e +9,0% no Gemma 4 26B, reduzindo as ocorrências de Falsa Convergência em até 66,7% (Projeto ARC-CEGIS 2026l,m).

A principal descoberta experimental reside na redefinição do modo de ação do prompt: embora formulado inicialmente para prevenir soluções fraudulentas no teste, o mecanismo atuou predominantemente como um **regularizador indutivo no espaço de busca durante o treino** e eliminou a *Oscilação por Ajustes Locais Conflitantes* — fonte de 80% a 90% do ganho de acurácia observado (Projeto ARC-CEGIS 2026f,m). Como benefício secundário, a convergência mais

direta reduziu o número médio de iterações por tarefa, proporcionando uma economia de até 5,2% no consumo de requisições à API (Projeto ARC-CEGIS 2026l).

Para trabalhos futuros, recomenda-se investigar o comportamento dessa restrição sob limites mais amplos de iteração ($T_{\max} = 10$), explorar a injeção dinâmica de restrições baseadas na sintaxe do erro e avaliar o impacto de regularizadores indutivos em arquiteturas de raciocínio profundo (*reasoning models*) (Projeto ARC-CEGIS 2026m).

Agradecimentos

Agradeço a orientação dos professores do Instituto de Informática da UFRGS pelo suporte metodológico durante o desenvolvimento deste projeto de pesquisa.

References

- Abate, A.; David, C.; Kesseli, P.; Kroening, D.; and Polgreen, E. 2018. Counterexample-Guided Inductive Synthesis Modulo Theories. In *Computer Aided Verification (CAV)*.
- Chollet, F. 2019. On the Measure of Intelligence. *arXiv preprint arXiv:1911.01547*.
- Projeto ARC-CEGIS. 2026a. Ambiente de Execução Isolado: `sandbox.py`. Documentação Interna do Projeto.
- Projeto ARC-CEGIS. 2026b. Auditoria Automatizada de Falsa Convergência: `analyze_false.py`. Documentação Interna do Projeto.
- Projeto ARC-CEGIS. 2026c. Camada de Acesso aos Modelos de Linguagem: `llm.py`. Documentação Interna do Projeto.
- Projeto ARC-CEGIS. 2026d. Carregamento das Tarefas do ARC-AGI-1: `data_loader.py`. Documentação Interna do Projeto.
- Projeto ARC-CEGIS. 2026e. Catálogo de *Prompts* Padrão e Anti-Trapça: `prompts.py`. Documentação Interna do Projeto.
- Projeto ARC-CEGIS. 2026f. Conclusões e Inspeção Qualitativa dos *Logs* de Execução. Documentação Interna do Projeto.
- Projeto ARC-CEGIS. 2026g. Guia de Replicação do Experimento ARC-AGI-1. Repositório de Código e Protocolos de Execução.
- Projeto ARC-CEGIS. 2026h. Hipótese: Prompt Anti-Cheat para Redução de Falsa Convergência no CEGIS. Documentação Interna do Projeto.

Projeto ARC-CEGIS. 2026i. Implementação do Laço CEGIS: `experiment.py`. Documentação Interna do Projeto.

Projeto ARC-CEGIS. 2026j. Metodologia Experimental: CEGIS Padrão vs. CEGIS Anti-Trapça. Documentação Interna do Projeto.

Projeto ARC-CEGIS. 2026k. Parâmetros de Execução e Poda de Contexto: `config.py`. Documentação Interna do Projeto.

Projeto ARC-CEGIS. 2026l. Relatório Científico e Análise Estatística Pós-Experimento. Resultados Oficiais do Projeto.

Projeto ARC-CEGIS. 2026m. Relatório Final Consolidado do Experimento CEGIS Anti-Trapça. Documentação Interna do Projeto.

Solar-Lezama, A. 2008. Program Synthesis by Sketching. *Ph.D. thesis, University of California, Berkeley*.

Zheng, L.; Chiang, W.-L.; Sheng, Y.; Li, T.; Zhuang, S.; Wu, Z.; Zhuang, Y.; Lin, Z.; Li, Z.; Li, D.; et al. 2023. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems*, 36.